Universidad de Buenos Aires

Facultad de Ciencias Exactas y Naturales

Departamento de Computación

Laboratorio de Datos

Trabajo Práctico 02 - Curso de Verano 2026

Clasificación y selección de modelos de distincion de letras

Nombre del Grupo: labubuntu

Integrantes	LU
Lanabere, Delfina Daniela	246/24
Muhafra, Micaela Abril	1327/24
Gomez Arreaza, Catherine De Jesus	980/24

Febrero 2026

1 Introducción

El propósito de este trabajo es analizar la base de datos de caracteres alfabéticos proporcionada y entrenar modelos de aprendizaje capaces de predecir la clase a la que pertenece cada imagen.

2 Análisis exploratorio

2.1 Relevancia de atributos

Los atributos relevantes son aquellos que se encuentran en la zona central de la imagen, como se ve en la figura 1 (aproximadamente entre las filas/columnas 5 y 23). Es allí donde se concentran los trazos en promedio. Sin embargo, la relevancia es relativa a la clase, ya que un píxel en la parte superior es crítico para distinguir una T de una L, pero irrelevante para diferenciar una I de una J, como se evidencia en la figura 2. Por otro lado, los atributos que carecen de relevancia son los píxeles de los márgenes externos. En los gráficos de las 26 letras, se ve que estos píxeles mantienen valores constantes (cercanos al color de fondo) independientemente de la letra representada. Dado que los valores de los bordes de las imágenes se mantienen constantes, se concluye que es posible reducir la imágen descartando estos atributos sin pérdida de información relevante.

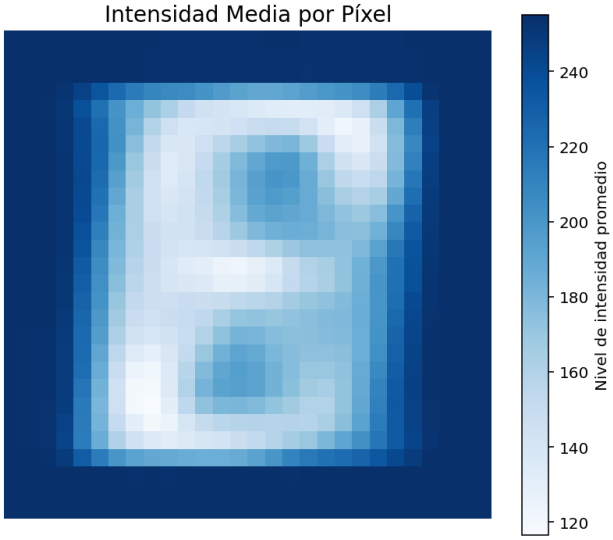

Figura 1: Mapa de color de la intensidad media por píxel para el dataset completo.

Figura 2: Promedio de intensidad por cada clase.

Al observar las imágenes promedio de la figura 2, se pueden comparar las clases y ver cuáles serán los problemas para los modelos al distinguir los diferentes caracteres.

En el caso de las letras O y Q, se observa una gran similitud general. Ambas comparten casi la totalidad de la disposición de sus píxeles, diferenciándose únicamente por el pequeño trazo de la “cola” en la esquina inferior derecha de la Q. Al trabajar con promedios, se tiende a suavizar rasgos considerados como críticos para la clasificación binaria posterior.

Por otro lado, las letras S y M son todo lo contrario. Mientras que la “S” concentra su intensidad en curvas más centrales, la M se caracteriza por tener trazos más rectos y en los bordes. Existe muy poco solapamiento entre sus píxeles más intensos, lo que permitiría que el modelo las clasifique con un margen de error mucho menor.

Para analizar la similitud dentro de una misma categoría, se seleccionaron muestras aleatorias de la letra J. Como se puede observar en la figura 3, existen diferencias significativas en la forma de los caracteres a pesar de pertenecer a la misma clase.

Estas variaciones incluyen cambios en la inclinación, el grosor del trazo y, principalmente, la presencia o ausencia de la curva inferior y la barra superior. Debido a esta gran diversidad, en el gráfico de promedios 2 se pueden ver varias zonas grises, las cuales son los píxeles que no son comunes a todas las formas de escribir la J y pierden intensidad en el promedio.

Figura 3: Distintas tipografías para la letra J.

Por último, en cuanto a la exploración de los datos en comparación con el dataset de Titanic, se observa una complejidad significativamente superior en el análisis de caracteres. Mientras que en el Titanic existían atributos no útiles en general (como el número de ticket), en este conjunto de datos la información no es tan simple de descartar.

Se requieren los 784 atributos para garantizar la completitud del dato a analizar; un píxel aislado no posee información útil por sí solo. Además, no siempre se puede obviar un píxel de forma general para todas las clases, ya que un trazo que es irrelevante para una letra puede ser el rasgo distintivo de otra.

3 Experimentos

3.1 Clasificación Binaria

El objetivo de esta sección consiste en determinar, a partir de una imagen, si la misma corresponde a la letra “O” o a la letra “L”. A partir del DataFrame original se construyó un subconjunto que contiene únicamente las imágenes correspondientes a estas dos clases. Dicho subconjunto se encuentra balanceado, ya que ambas letras poseen la misma cantidad de observaciones. Posteriormente, los datos fueron divididos aleatoriamente en un conjunto de entrenamiento (80 %) y un conjunto de prueba (20 %). Sobre el conjunto de entrenamiento se ajustó un modelo de K-Nearest Neighbors (KNN) con k = 2. La selección de atributos se realizó a partir de los siguientes criterios:

- **Diferencia de medias**: Se seleccionaron los píxeles que presentan mayor diferencia absoluta entre las medias de ambas letras.
- **Fisher score**: Se eligieron los píxeles con el mayor valor de “Fisher Score”, que favorece atributos con alta separación entre-clases y baja variabilidad intra-clase.
- **Selección aleatoria**: Se escogieron píxeles al azar.
- **Píxeles del borde**: se seleccionaron píxeles ubicados en los bordes de la imagen, que según el análisis exploratorio previo aportaban escasa información discriminativa.

Como métrica de evaluación se utilizó la exactitud (accuracy), que mide la proporción de predicciones correctas sobre el total de observaciones. Dado que el conjunto de datos está balanceado, esta métrica resulta adecuada y representativa para el objetivo del modelo.

Los resultados ilustrados en la figura 4 muestran que, al utilizar una cantidad reducida de atributos, el criterio basado en “Fisher Score” tiende a obtener el mejor desempeño. En estos casos, seleccionar variables que maximicen la separación entre clases y, al mismo tiempo, controlen la variabilidad intra-clase permite alcanzar una exactitud elevada incluso en baja dimensión. El criterio de diferencia de medias presenta un rendimiento muy cercano, aunque levemente inferior.

Por otro lado, se observa que los píxeles ubicados en los bordes presentan los peores desempeños. Esto confirma que dichas regiones no contienen información relevante para diferenciar las letras. La selección aleatoria de atributos mejora considerablemente estos resultados, lo que indica que, incluso sin criterio específico, muchos píxeles contienen información útil.

Al aumentar la cantidad de atributos, las diferencias entre los criterios se reducen. Tanto diferencia de medias como “Fisher Score” alcanzan desempeños muy altos y similares. Esto sugiere que, al incorporar una mayor cantidad de píxeles informativos, el modelo logra capturar de manera más completa la estructura discriminativa del problema, independientemente del criterio específico utilizado para seleccionarlos.

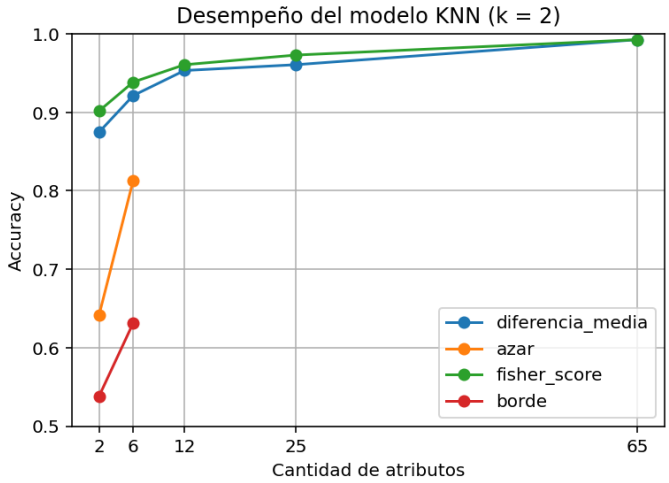

Figura 4: Exactitud de KNN en función de la cantidad de atributos (k = 2)

Para algunos de los conjuntos de atributos utilizados en el punto anterior, se volvió a ajustar el modelo KNN, incrementando el valor de k específicamente a k = 5 y k = 35 como se puede ver en la figura 5, con el objetivo de analizar cómo afecta este parámetro al rendimiento del modelo.

Al aumentar el k a 5 se observa un comportamiento relativamente estable en la mayoría de las configuraciones, sin embargo, puede notarse una ligera disminución en la exactitud que, al incrementar k a 35, se vuelve aún más evidente, especialmente cuando se utilizan muchos atributos. El modelo comienza a promediar regiones demasiado amplias del espacio, perdiendo sensibilidad a la estructura local de los datos.

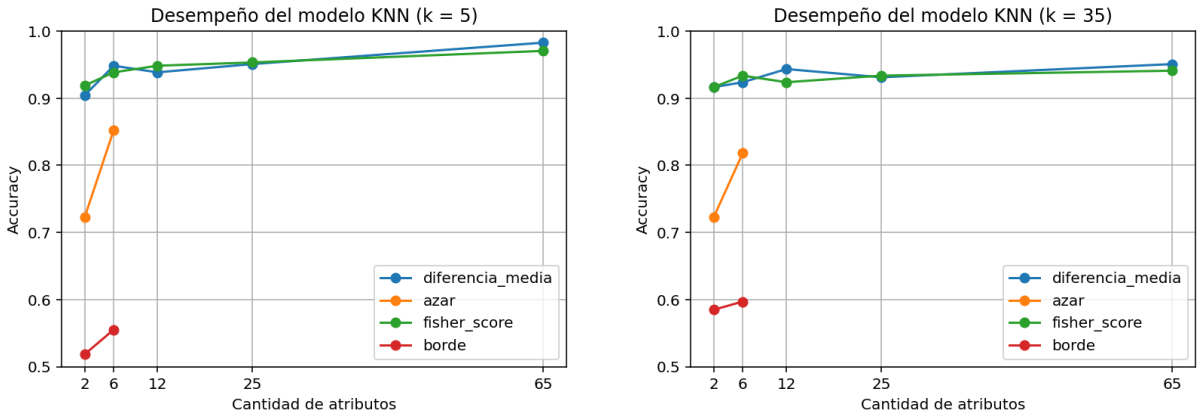

(a) k = 2

(b) k = 5

Figura 5: Exactitud de KNN en función a la cantidad de atributos (k = 5 y k = 35).

El peor desempeño se observa constantemente con los píxeles del borde, debajo de los seleccionados aleatoriamente, señalando la poca información aportada por estos, y como en general, la información discriminativa no se encuentra concentrada únicamente en unas pocas posiciones específicas, sino que está distribuida en distintas regiones de la imagen.

El mejor desempeño se obtiene con k = 2 y cantidad de atributos = 65, seleccionados bajo los criterios basados en diferencia de medias o “Fisher Score”, que alcanzan valores prácticamente idénticos y cercanos al máximo observado.Esto indica que, en este problema particular, la estructura de las clases presenta una separación suficientemente clara a nivel local, por lo que un valor pequeño de k resulta más adecuado para dicha estructura sin introducir un exceso de suavización en la frontera de decisión.

3.2 Clasificación multiclase

El objetivo de esta sección es dada una imagen, lograr determinar correctamente que a que letra corresponde.

Primero se divide el conjunto, donde se reserva un 15 % para la validación (held-out) y se usa el 85 % restante para el entrenamiento del programa (dev).
Se empieza por analizar la profundidad de un modelo de arbol de desición.

Se determinó hacer dos comparaciones, la primera de forma general usando entre 1 y 20 alturas, donde el rango no se muestra completo. Y luego enfocarse en los nodos más exactos y con menos overfitting con un rango completo para poder compararlas en detalle. Se dispuso de esta forma para achicar los tiempos de cómputo.

Como se puede ver la figura 6, a partir de los 17 nodos la presición del modelo sobre los casos de test se estanca. Y hasta los 9 nodos sigue mejorando. Por esto mismo se resolvió que el segundo gráfico se centre en estos valores. De esta figura (7) se deduce que para entrenar nuestro modelo, la altura ideal es de 11 nodos, pues los resultados de los conjuntos train y test empiezan a diverger más a partir del noveno nodo y esto implica que empiza a haber overfitting, pero la precisión de los casos de test sigue aumentando hasta el onceavo nodo de forma estable y luego lo empieza a hacer mucho más lentamente, tanto que casi no varía.

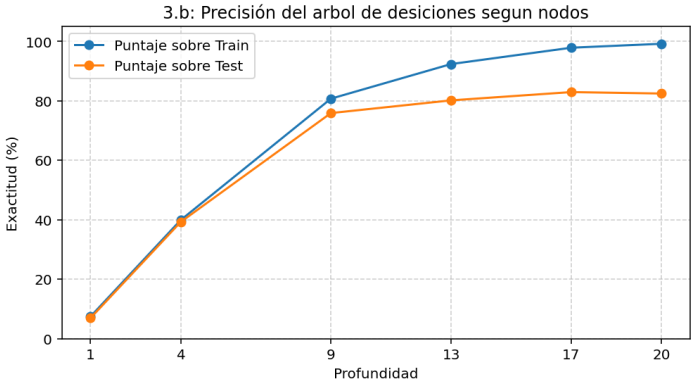

Figura 6: Evolución de la Exactitud según Profundidad del Árbol 1.

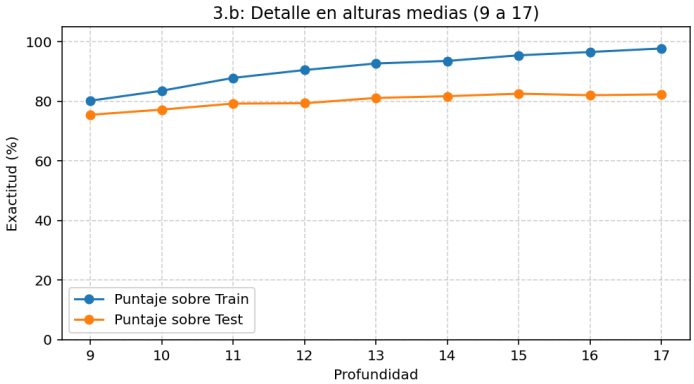

Figura 7: Evolución de la Exactitud según Profundidad del Árbol 2.

Luego se evaluarán los hiperparámetos, para esto se van a testear los criterios de las medidas de impureza (Gini y Entropy) y el límite de profundidad (entre 1 y 10 nodos).
Como se ve en el siguiente gráfico (8) a mayor profundidad, aumenta la precisión para ambos criterios, pero para árboles con 5 o más nodos, el rendimiento del criterio entrópico de las medidas de impureza es mejor que el de Gini. Y su rendimiento promedio es de 81.24 %.

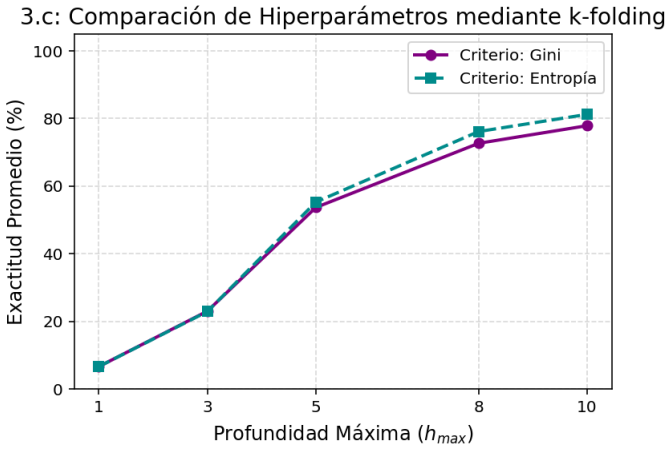

Figura 8: Comparación de hiperparámetros con k-folding.

Una vez definido el mejor modelo (11 nodos, criterio de entropía), solo queda entrenarlo sobre todo el conjunto de desarrollo.
Con el modelo entrenado se utiliza el conjunto held-out separado anteriormente para armar las predicciones para compararlas con las letras que representan realmente y así analizar la correctitud del modelo.
En la siguiente matriz de confusión (9) se representan las predicciones respecto a las letras verdaderas del conjunto Held-out.

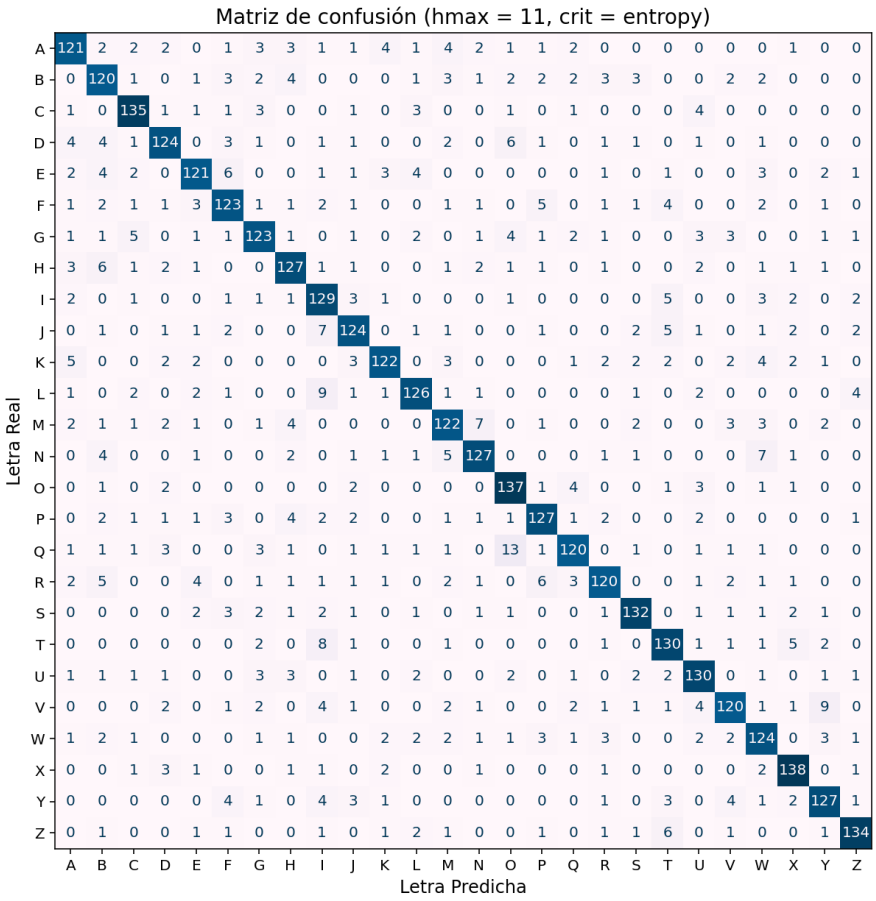

Figura 9: Matriz de Confusión.

Como se puede ver en la matriz, esta tiene una alta tasa de aciertos (un 82.84 % especificamente).

Y se pueden identificar la “X” cuya estructura es muy distinta a la del resto de las letras y la “O” que al ser un círculo cerrado tiene una estructura muy sólida, como las dos letras con mejor desempeño, con 138 y 137 aciertos respectivamente

Y con 120 aciertos cada una, son las “B” que se confunde con la “H” (4 veces) y la “D’ (4 veces) y la “Q” que se mezcla con la “O’ (13 veces, la confusión más grande de toda la matriz) pues el árbol no siempre logra detectar el “palito” de la Q y la clasifica como un círculo simple (O), las dos letras con menor desempeño.

Por otro lado, si separamos las letras por su forma, podemos armar los conjuntos de letras: Verticales o Rectas (G_V): $\{E, F, T, L, H, R, P, B\}$. que tienen un eje vertical dominante y barras horizontales, Redondas (G_R): $\{C, G, O, Q, U\}$. Definidas por estructuras circulares o arcos de gran curvatura y Diagonales (G_D): $\{A, X, W, N, M, V, \tilde{N}, Y\}$. Compuestas por vectores que no se alinean con los ejes principales de la matriz. Con los resultados de la matriz de confución se puede notar que la mayoría de los errores son dentros de un mismo grupo.

Al hacer un mapa de calor que muestre los pixeles más importantes para la toma de desiciones, se puede ver (en la figura 10) que los píxeles más importantes se encuentran en el centro (donde se cruzan las H, se cierran las O y se unen las A), esto explica la confusion en los detalles de las letras (como la diferencia entre la O y la Q) pues estos se suelen encontrar en la periferia de las imágenes.

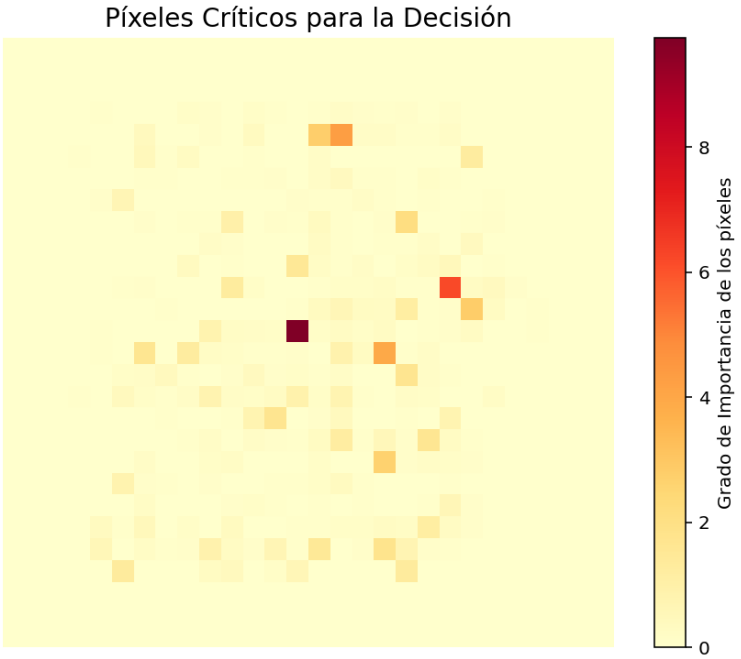

Figura 10: Importancia de píxeles.

4 Conclusiones

A lo largo de este informe, se buscó clasificar caracteres alfabéticos mediante modelos de aprendizaje supervisado y se extrajeron las siguientes conclusiones:

Localización de elementos: El análisis exploratorio mostró que algunos píxeles dan más información que otros. Los trazos de las letras se concentran en la zona central de la imagen (filas/columnas 5 a 23), mientras que en los márgenes casi no hay información.

Complejidad de la Clasificación Binaria (O vs L):Se demostró que la elección del criterio de selección de atributos es muy importante. El método Fisher Score superó a la selección aleatoria y a la diferencia de medias pues maximiza la separación entre clases y controla la varianza interna. En cuanto al modelo KNN, se vió que un valor bajo de vecinos (k=2) resultó más efectivo. Aumentar k (especialmente a 35) provocó que baje el desempeño, perdiendo la estructura local de los datos.

Optimización del Modelo Multiclase:Para la clasificación de las 26 letras, el Árbol de Decisión alcanzó su punto óptimo de equilibrio entre precisión y generalización con una profundidad de 11 nodos. Superar esta altura incrementaba el riesgo de overfitting sin mejoras sustanciales en el conjunto de prueba. El criterio de Entropía demostró ser superior al de Gini para árboles de mayor complejidad (más de 5 nodos), logrando una exactitud final del 82.84 % en el conjunto de validación (held-out).

La matriz de confusión evidenció que los errores no son aleatorios, sino que ocurren principalmente entre letras visualmente similares. Las mayores dificultades se presentaron en el grupo de letras Redondas (como la confusión entre “Q” y “O” por la dificultad de detectar la ’cola’ de la Q) y en letras con ejes verticales dominantes como la “B”, “H” y “D”.

A diferencia de otros conjuntos de datos más estructurados (como la del Titanic), el análisis de imágenes requiere considerar la interacción de todos los atributos. Un píxel por si mismo no da ninguna información, y su relevancia depende resto de la imagen y como se la pretende clasificar.